LAPORAN PRAKTIKUM
MACHINE LEARNING

DOSEN PENGAMPU: ASEP ERLAN MAULANA, S.KOM., M.KOM.

DISUSUN OLEH:

SANDY SETIAWAN **241011400869**

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS PAMULANG

KOTA TANGERANG SELATAN

2026

DAFTAR ISI

DAFTAR ISI ..... **i**
DAFTAR GAMBAR ..... **ii**
BAB I **1**
PENDAHULUAN **1**
1.1. Latar Belakang 1
1.2. Tujuan Praktikum 3
BAB II **4**
PEMBAHASAN PRAKTIKUM **4**
2.1. Persiapan Dataset 4
2.2. Analisis Data Eksploratif (Exploratory Data Analysis) 7
2.3. Pemrosesan Data (Data Preprocessing) 9
2.4. Pemilihan Model (Model Selection) 14
2.5. Evaluasi Model (Model Evaluation) 15
BAB III **18**
PENUTUP **18**
3.1. Kesimpulan 18
3.2. Saran 19
DAFTAR PUSTAKA **21**

DAFTAR GAMBAR

Gambar 1 : Sumber Dataset 4
Gambar 2 : Tampilan Hasil Eksekusi *Script* Python 5
Gambar 3 : Tampilan Informasi Dataset 6
Gambar 4 : Visualisasi Fitur Kategorik 9
Gambar 5 : *Output* Pengecekan Data Hilang dan Duplikat 11
Gambar 6 : *Output* Fitur yang Terdapat *Outliers* 11
Gambar 7 : Hasil One-Hot Encoding 13
Gambar 8 : *Classification Report* Model Regresi Logistik 16
Gambar 9 : *Classification Report* Model SVM 16
Gambar 10 : *Classification Report* Model Decision Tree 17

BAB I
PENDAHULUAN

1.1. Latar Belakang

Penyakit jantung merupakan salah satu masalah kesehatan yang memerlukan perhatian karena menjadi penyebab utama kematian dan menimbulkan beban kesehatan yang besar secara global (Wilson et al., 1998; Mohan et al., 2019; Al-Alshaikh et al., 2024). Risiko penyakit jantung berkaitan dengan berbagai faktor, termasuk usia, jenis kelamin, tekanan darah, kadar kolesterol, diabetes, dan kebiasaan merokok (Wilson et al., 1998; Jousilahti et al., 1999; van Bussel et al., 2020; Iakunchykova et al., 2023). Pada penyakit jantung koroner, kejadian penyakit pada laki-laki lebih tinggi daripada perempuan, dan risiko meningkat seiring bertambahnya usia (Jousilahti et al., 1999). Sebagian perbedaan risiko menurut jenis kelamin dan usia ini dapat dijelaskan oleh perbedaan faktor risiko kardiovaskular utama seperti HDL, merokok, kolesterol total, tekanan darah, indeks massa tubuh, dan diabetes (Jousilahti et al., 1999).

Pemeriksaan elektrokardiogram atau ECG juga relevan dalam evaluasi penyakit kardiovaskular karena dapat digunakan untuk mengidentifikasi dan mengukur abnormalitas yang berkaitan dengan risiko penyakit jantung (Sahranavard et al., 2024). Abnormalitas ECG berasosiasi dengan hipertensi, diabetes, merokok, aktivitas fisik, usia yang lebih tua, obesitas, dan hiperkolesterolemia (Sahranavard et al., 2024; Yu et al., 2020; Ahmadi et al., 2025). Pada perempuan, usia dan hipertensi tampak berhubungan kuat dengan abnormalitas ECG mayor maupun minor, sedangkan pada laki-laki hipertensi dan diabetes lebih menonjol pada abnormalitas mayor (Sahranavard et al., 2024). Karena itu, analisis data kesehatan penting untuk memahami karakteristik pasien dan mendukung identifikasi pola risiko penyakit jantung (Pencina et al., 2018; van Bussel et al., 2020).

Perkembangan teknologi informasi dan pengolahan data memungkinkan data kesehatan dimanfaatkan untuk menghasilkan informasi yang lebih terstruktur dan mendukung prediksi penyakit (Mohan et al., 2019; El-Sofany, 2025; Lakshmanan

& M., 2025). Salah satu pendekatan yang banyak digunakan adalah machine learning, yaitu metode komputasi yang mempelajari pola dari data untuk menghasilkan prediksi atau klasifikasi (El-Sofany, 2025). Dalam bidang kesehatan, machine learning telah digunakan untuk membantu diagnosis, deteksi dini, dan prediksi penyakit jantung menggunakan data klinis dan faktor risiko pasien (Bhatt et al., 2023; Ali et al., 2021; Rehman et al., 2025).

Namun, kinerja model sangat dipengaruhi oleh kualitas data, seleksi fitur, penanganan ketidakseimbangan kelas, serta metode validasi dan evaluasi yang digunakan (Gárate-Escamila et al., 2020; Jrab et al., 2024; Al-Alshaikh et al., 2024; Rehman et al., 2025). Beberapa studi menunjukkan bahwa algoritma seperti Random Forest, Support Vector Machine, Logistic Regression, Decision Tree, XGBoost, multilayer perceptron, dan model hibrida dapat memberikan akurasi yang tinggi, tetapi hasilnya tetap bervariasi antar dataset dan rancangan penelitian (Mohan et al., 2019; Bhatt et al., 2023; Ali et al., 2021; Lakshmanan & M., 2025; Özcan & Peker, 2022). Variasi ini menunjukkan bahwa model machine learning berguna sebagai alat bantu analitik, tetapi performanya tetap perlu dievaluasi secara hati-hati sebelum diinterpretasikan lebih lanjut (van Bussel et al., 2020; Pencina et al., 2018).

Pada praktikum ini, dataset Heart Disease Prediction digunakan sebagai objek analisis untuk mempelajari karakteristik data dan penerapan klasifikasi penyakit jantung. Variabel seperti usia, jenis kelamin, tekanan darah, kolesterol, denyut jantung maksimum, dan hasil ECG memang termasuk fitur yang sering digunakan dalam penelitian prediksi penyakit jantung (Al-Alshaikh et al., 2024; Sinha et al., 2025; Lakshmanan & M., 2025). Fitur seperti ST slope, oldpeak, tekanan darah saat istirahat, dan hasil ECG juga dilaporkan sebagai prediktor penting pada beberapa penelitian (Gárate-Escamila et al., 2020; Sinha et al., 2025; Özcan & Peker, 2022). Dengan demikian, penggunaan dataset ini relevan untuk mempelajari hubungan antarvariabel serta bagaimana variabel target HeartDisease dapat diklasifikasikan ke dalam dua kelas berdasarkan pola data yang tersedia (Özcan & Peker, 2022; Ali et al., 2021).

Tahapan praktikum dapat mencakup eksplorasi data, pemeriksaan kualitas data, prapemrosesan, seleksi fitur, pelatihan model, dan evaluasi kinerja menggunakan metrik seperti akurasi, sensitivitas, spesifisitas, F1-score, dan AUC (El-Sofany, 2025; Jrab et al., 2024; Al-Alshaikh et al., 2024). Validasi silang dan optimasi hiperparameter juga umum digunakan untuk memperoleh penilaian model yang lebih andal (Bhatt et al., 2023; Jrab et al., 2024). Tahapan tersebut bertujuan untuk memahami proses pengolahan data secara sistematis serta menilai kemampuan model dalam mengklasifikasikan data berdasarkan pola yang dipelajari (Ali et al., 2021; Özcan & Peker, 2022).

1.2. Tujuan Praktikum

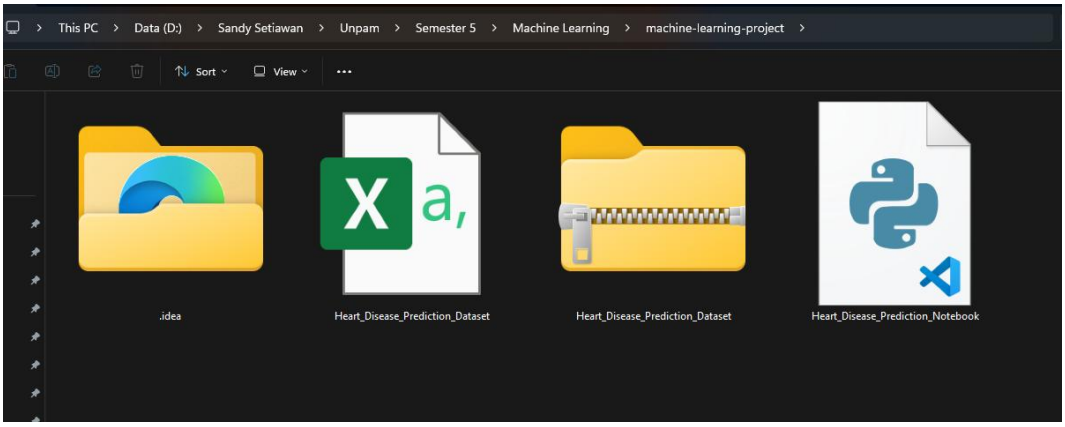
a. Memahami karakteristik dan struktur dataset Heart Disease Prediction yang terdiri atas variabel-variabel terkait kondisi kesehatan pasien.
b. Melakukan eksplorasi dan analisis data untuk mengidentifikasi pola serta distribusi variabel yang berkaitan dengan status penyakit jantung.
c. Memahami dan menerapkan tahapan prapemrosesan data (data preprocessing) agar dataset siap digunakan dalam proses analisis atau pemodelan.
d. Menerapkan konsep Machine Learning untuk membangun model klasifikasi status penyakit jantung berdasarkan variabel yang tersedia dalam dataset.
e. Mengevaluasi kinerja model klasifikasi menggunakan metrik evaluasi yang sesuai untuk mengetahui kemampuan model dalam mengklasifikasikan status penyakit jantung.

BAB II
PEMBAHASAN PRAKTIKUM

2.1. Persiapan Dataset

Pada tahap pertama dalam sebuah *machine learning workflow*, penulis akan terlebih dahulu menyiapkan *dataset*-nya. Dalam hal ini, dataset diperoleh melalui situs Kaggle, yaitu sebuah situs yang menyediakan beragam jenis data, dari mulai data untuk kasus regresi, klasifikasi, teks, audio, hingga gambar.

Dataset yang diperoleh diketahui bernama **`heart.csv`** pada awalnya. Namun, untuk memudahkan penulis dan pembaca ke depannya, penulis akan mengganti namanya menjadi **`Heart_Disease_Prediction_Dataset.csv`**.



Gambar 1: Sumber Dataset

Selanjutnya, penulis akan mencoba untuk memahami isi dari *dataset* tersebut, dari mulai dengan memuat data, menampilkan isi data, dan menampilkan informasi mengenai struktur dari data tersebut. Dalam hal ini, penulis menggunakan beberapa *script* berikut yang merupakan bahasa pemrograman Python, untuk menjalankan tugas tersebut.

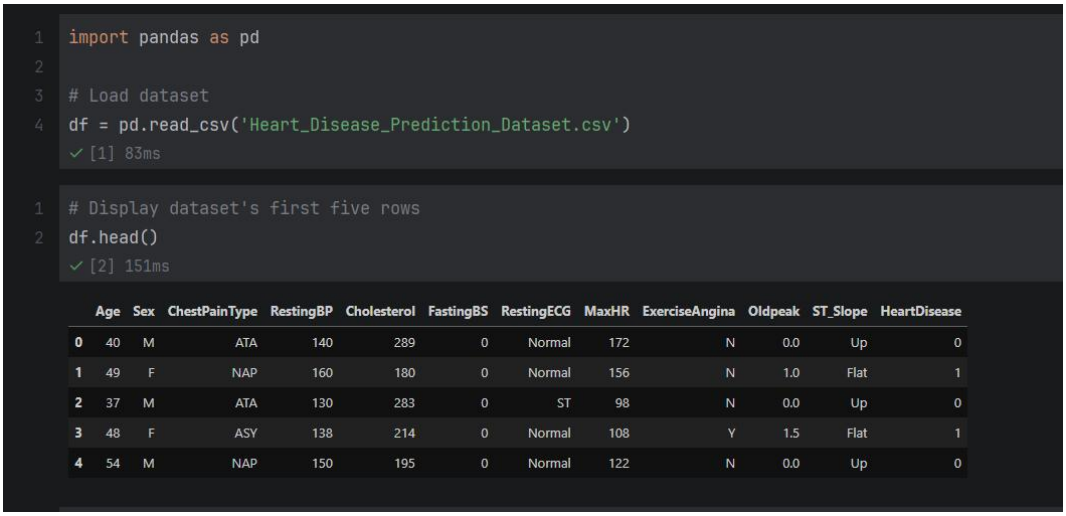
```
import pandas as pd

# Load dataset
df = pd.read_csv('Heart_Disease_Prediction_Dataset.csv')
```

```
# Display dataset's first five rows
df.head()

# Display dataset's information
df.info()
```

Dari eksekusi *script* Python tersebut, penulis mendapatkan beberapa hasil terkait *dataset* tersebut.



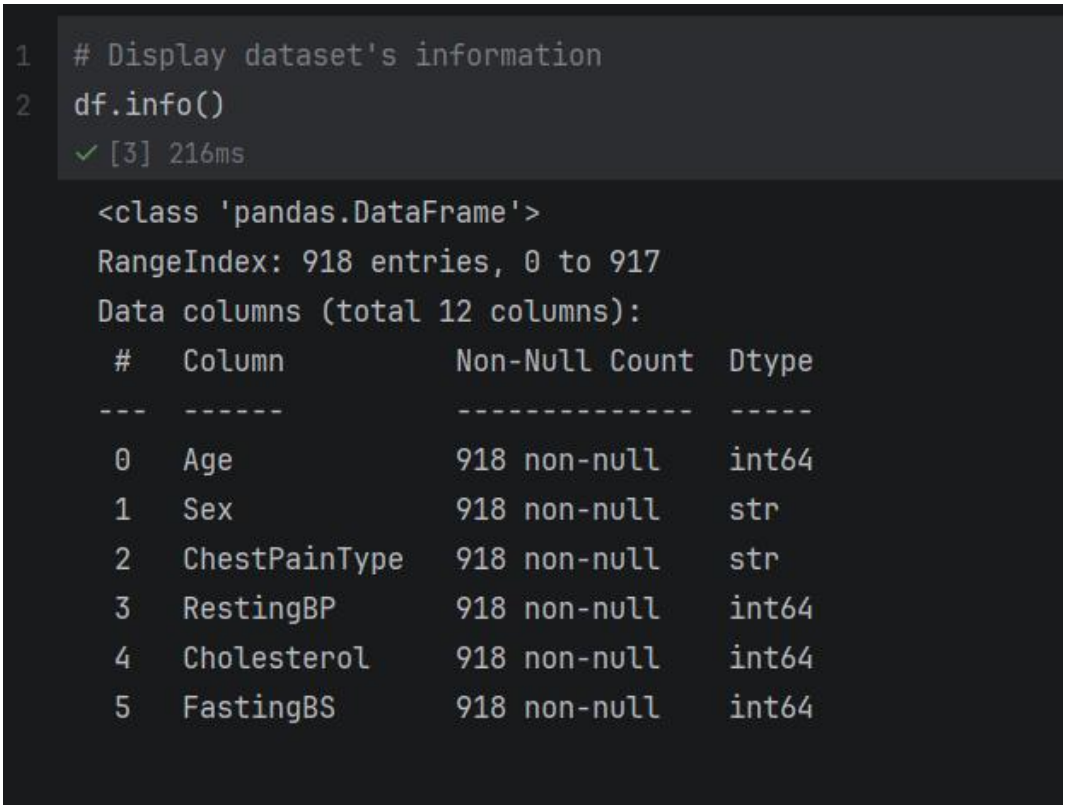
```
import pandas as pd

# Load dataset
df = pd.read_csv('Heart_Disease_Prediction_Dataset.csv')
✓ [1] 83ms
```

```
# Display dataset's first five rows
df.head()
✓ [2] 151ms
```

	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope	HeartDisease
0	40	M	ATA	140	289	0	Normal	172	N	0.0	Up	0
1	49	F	NAP	160	180	0	Normal	156	N	1.0	Flat	1
2	37	M	ATA	130	283	0	ST	98	N	0.0	Up	0
3	48	F	ASY	138	214	0	Normal	108	Y	1.5	Flat	1
4	54	M	NAP	150	195	0	Normal	122	N	0.0	Up	0

Gambar 2: Tampilan Hasil Eksekusi *Script* Python



Gambar 3: Tampilan Informasi Dataset

Dikarenakan terdapat batasan tampilan ketika mengeksekusi perintah df.info(), yang di mana informasinya tidak lengkap, maka penulis akan menulisnya ulang sebagai berikut.

```
<class 'pandas.DataFrame'>
RangeIndex: 918 entries, 0 to 917
Data columns (total 12 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   Age             918 non-null    int64
 1   Sex             918 non-null    str
 2   ChestPainType   918 non-null    str
 3   RestingBP       918 non-null    int64
 4   Cholesterol     918 non-null    int64
 5   FastingBS       918 non-null    int64
```

```
 6   RestingECG      918 non-null    str
 7   MaxHR           918 non-null    int64
 8   ExerciseAngina  918 non-null    str
 9   Oldpeak         918 non-null    float64
 10  ST_Slope        918 non-null    str
 11  HeartDisease    918 non-null    int64
dtypes: float64(1), int64(6), str(5)
memory usage: 97.6 KB
```

Diketahui bahwa ternyata *dataset* tersebut terdiri dari 12 fitur atau kolom dan jumlah baris data sebanyak 918.

2.2. Analisis Data Eksploratif (Exploratory Data Analysis)

Pada tahap ini, akan dilakukan sebuah proses untuk menemukan *insight* atau wawasan terkait *dataset* yang dipilih. Dalam kasus ini, penulis mencoba mencari wawasan terkait data ini dengan cara menampilkan informasi statistik dari *dataset* dan menampilkan visualisasi data. Namun, sebelum menampilkan visualisasi, penulis terlebih dahulu memisahkan kolom numerik dengan kolom kategorik untuk kesesuaian jenis visualisasi. Berikut adalah kode program yang penulis gunakan.

```
# Display dataset's statistics information
df.describe()

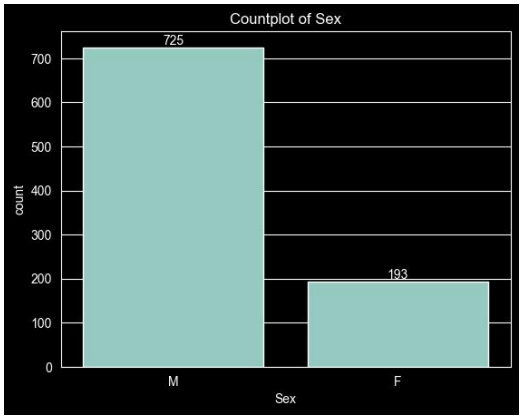
# Separate the numerical features and the categorical features
num_cols = df.select_dtypes(include='number').columns
cat_cols = df.select_dtypes(include='object').columns

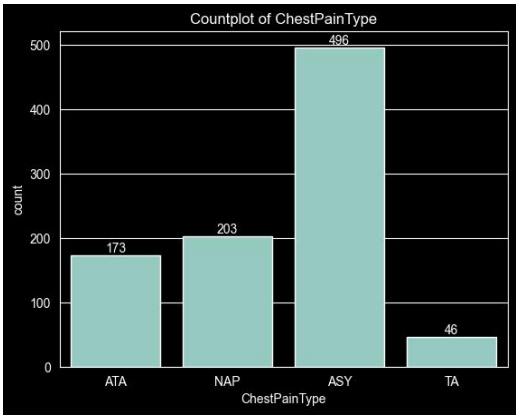
import matplotlib.pyplot as plt
import seaborn as sns
```

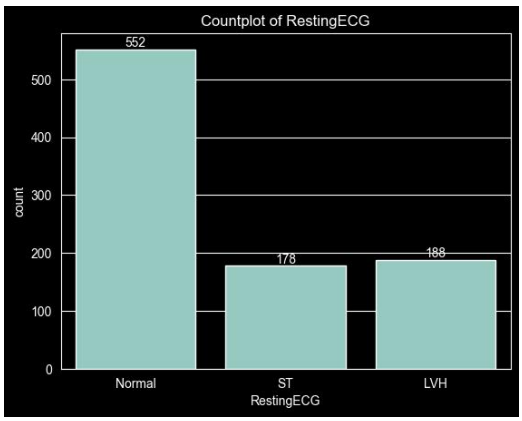
```
# Display countplot visualization for categorical columns
for col in cat_cols:
    ax = sns.countplot(x=col, data=df)
    ax.bar_label(ax.containers[0])
    plt.title(f'Countplot of {col}')
    plt.show()

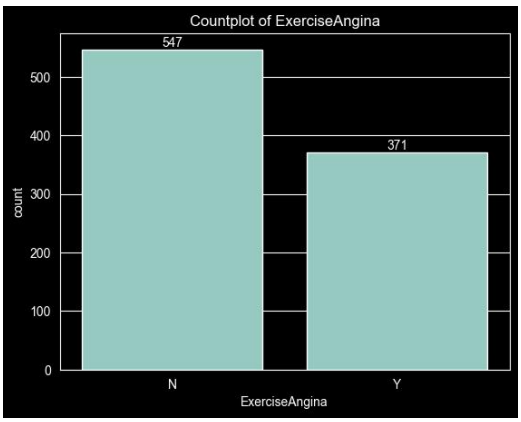
# Display histogram plot for numerical features
for col in num_cols:
    sns.histplot(data=df, x=col)
    plt.title(f'Histogram of {col}')
    plt.show()
```

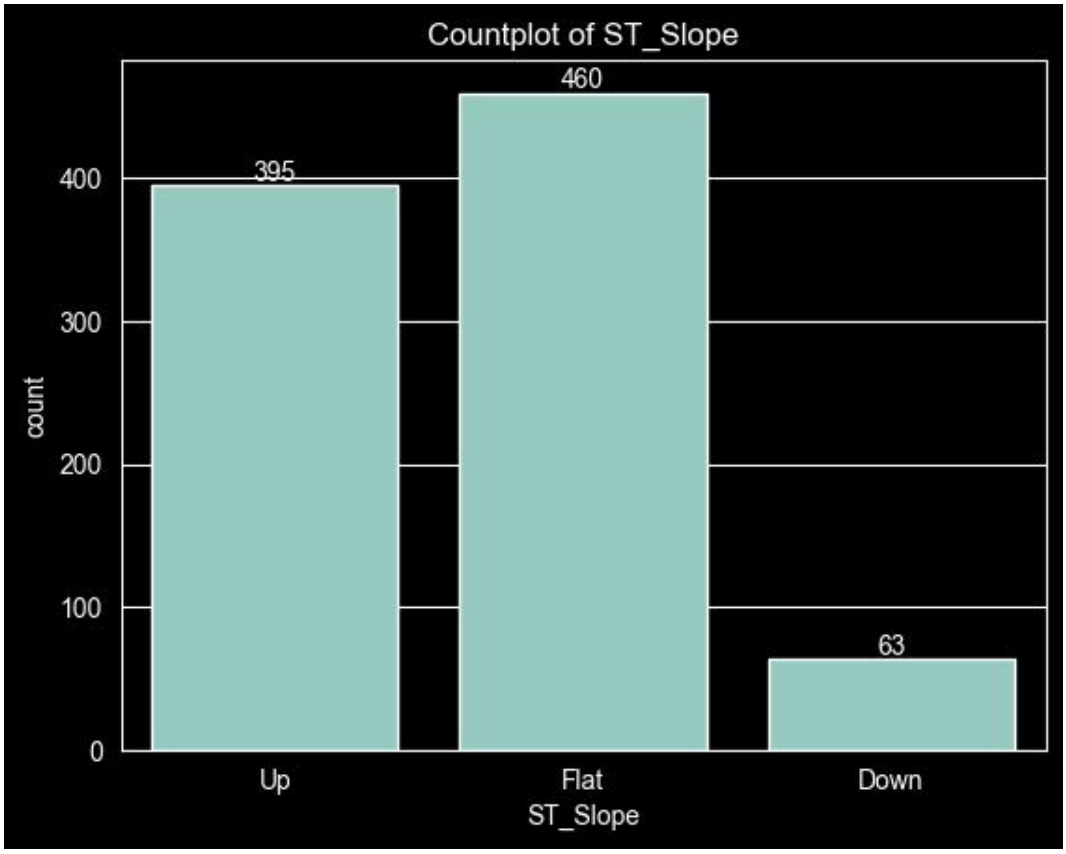
Berdasarkan kode program yang telah dieksekusi, maka akan tampil beberapa *output* seperti berikut.











Gambar 4: Visualisasi Fitur Kategorik

2.3. Pemrosesan Data (Data Preprocessing)

Pemrosesan data melibatkan serangkaian proses yang sifatnya dapat berulang-ulang. Secara umum, prosesnya terdiri pembersihan data (*data cleaning*) dan pelabelan data kategorik (*label encoding*).

Pada kasus ini, penulis terlebih dahulu memulainya dengan melakukan pengecekan terhadap data yang hilang, duplikat, dan juga data pencilan (*outliers*). Data pencilan merupakan data yang nilainya terpaut jauh atau menyimpang sangat signifikan dari mayoritas data lainnya. Berikut penulis berikan kode program Python dan hasil dari kode program tersebut.

```
# Check for null values
df.isnull().sum()
```

```
# Check for duplicated values
df.duplicated().sum()

# Check for outliers using boxplot visualization
df.boxplot()

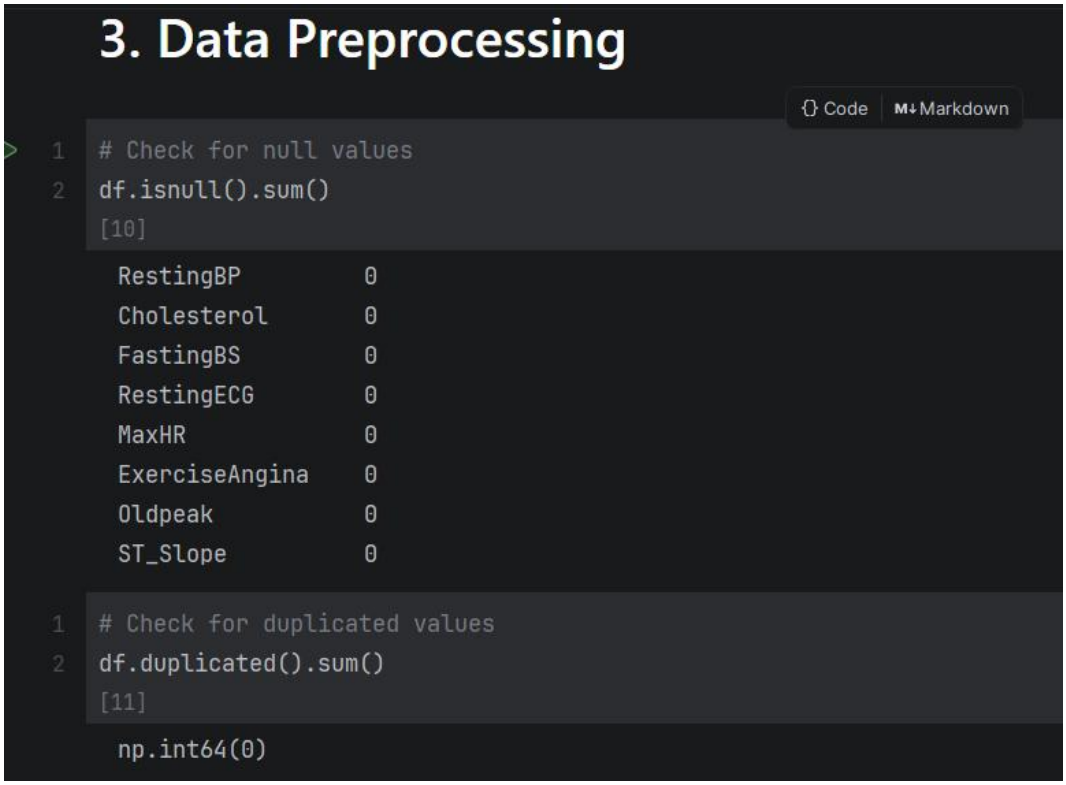
# Check for outliers using IQR methods
for col in num_cols:
    Q1 = df[col].quantile(.25)
    Q3 = df[col].quantile(.75)
    IQR = Q3 - Q1

    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR

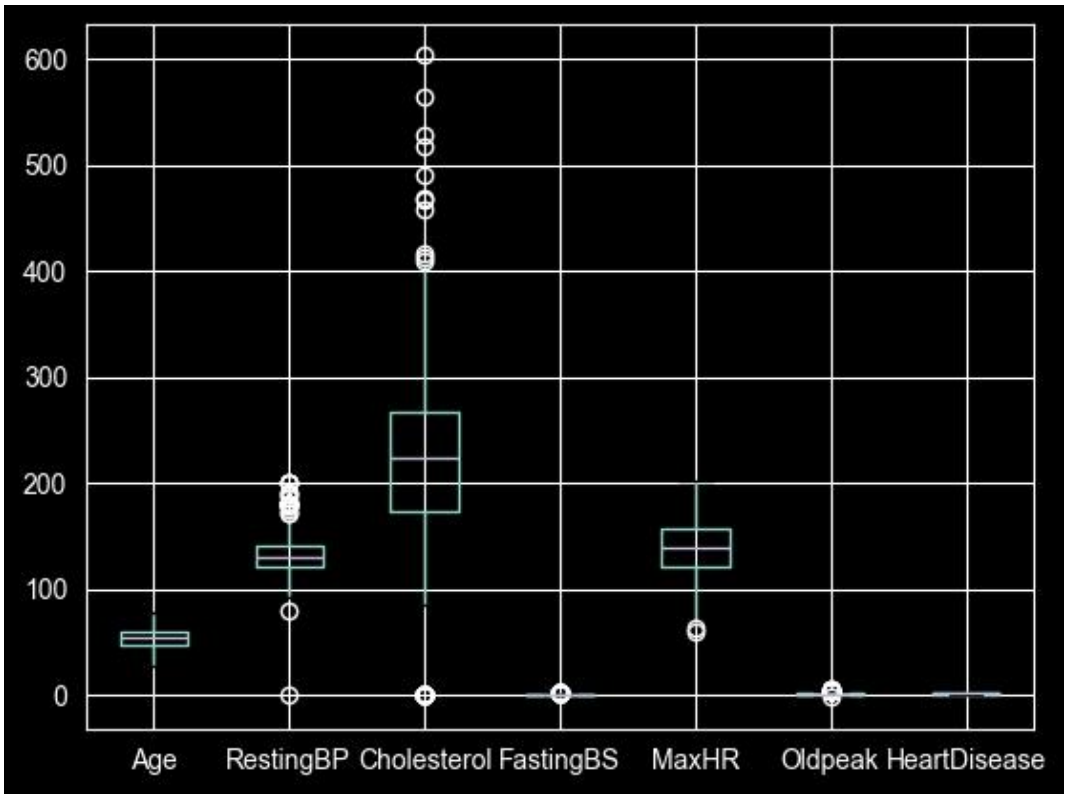
    outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]

    print(outliers[[col]])
```

Berikut adalah output yang dihasilkan dari kode program tersebut.



Gambar 5: *Output* Pengecekan Data Hilang dan Duplikat



Gambar 6: *Output* Fitur yang Terdapat *Outliers*

Setelah dilakukan pengecekan terhadap *dataset* tersebut, maka langkah selanjutnya adalah melakukan pembersihan utamanya. Dikarenakan *dataset* ini tidak memiliki data yang hilang dan duplikat, maka penulis akan melewati tahapan ini, dan akan fokus untuk mengatasi data pencilan dengan mengimputasinya dengan nilai median dari setiap fiturnya. Berikut penulis jabarkan kode program untuk mengatasi data pencilan tersebut.

```
# Handling outliers using imputation techniques
for col in num_cols:
    Q1 = df[col].quantile(0.25)
    Q3 = df[col].quantile(0.75)
    IQR = Q3 - Q1

    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR

    # Median kolom
    median_value = df[col].median()

    # Imputasi: ganti nilai outlier dengan median
    df.loc[(df[col] < lower_bound) | (df[col] > upper_bound),
col] = median_value
```

Pada kode program di atas, sekilas ketika Anda jalankan tidak akan terjadi apa-apa. Dikarenakan prosesnya bersifat internal atau perubahannya dilakukan di dalam *dataset*-nya langsung. Pada kode tersebut, data yang dianggap sebagai pencilan akan diganti (diimputasi) dengan data median dari kolom tersebut.

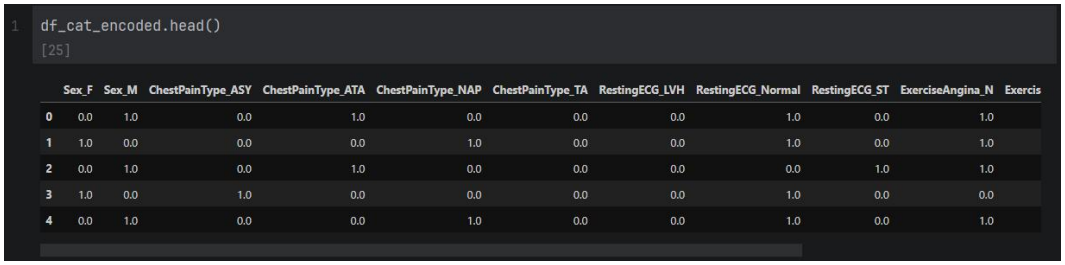
Pada langkah selanjutnya, penulis akan menerapkan pelabelan terhadap fitur kategorik menggunakan teknik One-Hot Encoding. Singkatnya, metode ini memungkinkan nilai dari sebuah fitur diubah menjadi angka yang dapat diproses oleh algoritma *machine learning* di proses yang akan datang. Nilai fitur tersebut diubah menjadi angka biner (0 atau 1). Berikut penulis berikan kode programnya.

```
from sklearn.preprocessing import LabelEncoder, OneHotEncoder

# le_encoder = LabelEncoder()
ohe_encoder = OneHotEncoder(sparse_output=False)

df_cat_encoded = pd.DataFrame(ohe_encoder.fit_transform(df[cat_cols]), columns=ohe_encoder.get_feature_names_out())
```

Kode program tersebut, akan menghasilkan sebuah *dataframe* baru yang nilai kategoriknya sudah diubah menjadi bilangan biner, yaitu sebagai berikut.



```
df_cat_encoded.head()
[25]
```

	Sex_F	Sex_M	ChestPainType_ASY	ChestPainType_ATA	ChestPainType_NAP	ChestPainType_TA	RestingECG_LVH	RestingECG_Normal	RestingECG_ST	ExerciseAngina_N	Exercis
0	0.0	1.0	0.0	1.0	0.0	0.0	0.0	1.0	0.0	1.0	
1	1.0	0.0	0.0	0.0	1.0	0.0	0.0	1.0	0.0	1.0	
2	0.0	1.0	0.0	1.0	0.0	0.0	0.0	0.0	1.0	1.0	
3	1.0	0.0	1.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	
4	0.0	1.0	0.0	0.0	1.0	0.0	0.0	1.0	0.0	1.0	

Gambar 7: Hasil One-Hot Encoding

Langkah terakhir, penulis akan menggabungkan seluruh *dataframe* terpisah menjadi satu kesatuan yang utuh, yang disebut sebagai **df_cleaned**, menandai bahwa *dataframe* ini berisikan data yang telah diproses dan siap untuk diberikan kepada model *machine learning*. Penulis juga melakukan label manual terhadap fitur "HeartDisease" dari angka biner (0 dan 1) menjadi "Not Heart Disease" dan "Heart Disease". Berikut penulis sertakan kode programnya.

```
# Combine the preprocessed features into single dataframe
df_cleaned = pd.concat([df[num_cols], df_cat_encoded], axis=1)

# Manual label encoding for 'HeartDisease'
df_cleaned['HeartDisease'] =
```

```
df_cleaned['HeartDisease'].map({
    0: 'Not Heart Disease',
    1: 'Heart Disease'
})
```

2.4. Pemilihan Model (Model Selection)

Pada tahapan ini, akan dilakukan sebuah proses pembuatan model *machine learning*-nya. Karena kasus ini merupakan kasus klasifikasi, maka penulis akan menggunakan model-model klasifikasi. Namun, sebelum ke tahapan utama, penulis akan memisah fitur independen dan fitur dependennya terlebih dahulu, lalu membuat variabel pelatihan (*training set*) dan pengujian (*testing set*).

```
from sklearn.model_selection import train_test_split

# Data splitting
X = df_cleaned.drop('HeartDisease', axis=1)
y = df_cleaned['HeartDisease']

# Split dataset into training set and testing set
X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.2, random_state=42)
```

Pada tahap pembuatan model, penulis akan menggunakan 3 (tiga) algoritma *machine learning* yang cukup populer, yaitu Regresi Logistik (Logistic Regression), Support Vector Machine (SVM), dan Decision Tree (klasifikasi). Berikut penulis sertakan kode programnya.

```
from sklearn.linear_model import LogisticRegression
from sklearn.svm import SVC
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import classification_report

models = [
```

```
    LogisticRegression(),
    SVC(),
    DecisionTreeClassifier(),
]

for model in models:
    model.fit(X_train, y_train)

    y_pred_train = model.predict(X_train)
    y_pred_test = model.predict(X_test)

    train_cr = classification_report(y_train, y_pred_train)
    test_cr = classification_report(y_test, y_pred_test)

    print(f'Training Set Classification Report of {model}:')
    print(train_cr)
    print(f'Testing Set Classification Report of {model}:')
    print(test_cr)
```

Dari kode program tersebut akan menghasilkan sebuah keluaran berupa *Classification Report* dari setiap model. *Classification Report* tersebut berisikan seluruh metrik akurasi dari sebuah model. Metrik tersebut dapat Anda lihat di langkah selanjutnya.

2.5. Evaluasi Model (Model Evaluation)

Pada tahapan ini, penulis akan menampilkan *Classification Report* dari setiap model *machine learning* yang telah dilatih. Berikut penulis sertakan gambarnya.

Training Set Classification Report of LogisticRegression():

	precision	recall	f1-score	support
Heart Disease	0.86	0.88	0.87	401
Not Heart Disease	0.85	0.83	0.84	333
accuracy			0.86	734
macro avg	0.86	0.85	0.86	734
weighted avg	0.86	0.86	0.86	734

Testing Set Classification Report of LogisticRegression():

	precision	recall	f1-score	support
Heart Disease	0.91	0.82	0.86	107
Not Heart Disease	0.78	0.88	0.83	77
accuracy			0.85	184
macro avg	0.84	0.85	0.85	184
weighted avg	0.85	0.85	0.85	184

Gambar 8: *Classification Report* Model Regresi Logistik

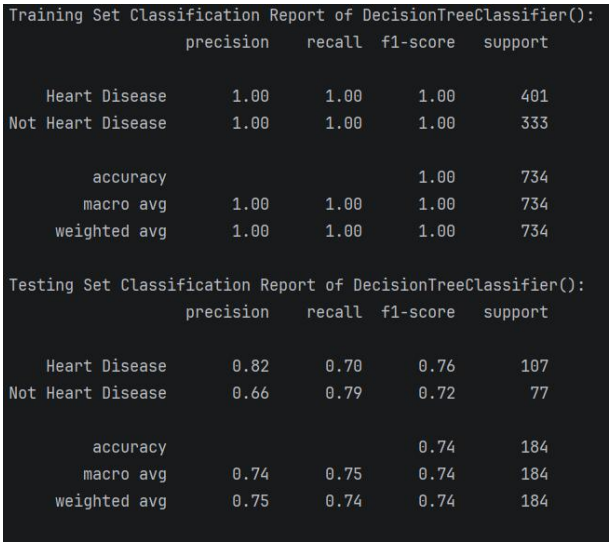
Training Set Classification Report of SVC():

	precision	recall	f1-score	support
Heart Disease	0.70	0.77	0.73	401
Not Heart Disease	0.69	0.60	0.64	333
accuracy			0.69	734
macro avg	0.69	0.69	0.69	734
weighted avg	0.69	0.69	0.69	734

Testing Set Classification Report of SVC():

	precision	recall	f1-score	support
Heart Disease	0.71	0.69	0.70	107
Not Heart Disease	0.59	0.61	0.60	77
accuracy			0.66	184
macro avg	0.65	0.65	0.65	184
weighted avg	0.66	0.66	0.66	184

Gambar 9: *Classification Report* Model SVM



Training Set Classification Report of DecisionTreeClassifier():

	precision	recall	f1-score	support
Heart Disease	1.00	1.00	1.00	401
Not Heart Disease	1.00	1.00	1.00	333
accuracy			1.00	734
macro avg	1.00	1.00	1.00	734
weighted avg	1.00	1.00	1.00	734

Testing Set Classification Report of DecisionTreeClassifier():

	precision	recall	f1-score	support
Heart Disease	0.82	0.70	0.76	107
Not Heart Disease	0.66	0.79	0.72	77
accuracy			0.74	184
macro avg	0.74	0.75	0.74	184
weighted avg	0.75	0.74	0.74	184

Gambar 10: *Classification Report* Model Decision Tree

Dari ketiga gambar tersebut, dapat disimpulkan bahwa model regresi logistik menjadi pemenang dari hal akurasi pada kasus ini. Baik dalam pelatihan maupun pengujian, model regresi logistik konsisten mempertahankan akurasinya di angka 0,86 (86%) untuk pelatihan dan 0,85 (85%) untuk pengujian.

BAB III
PENUTUP

3.1. Kesimpulan

Berdasarkan praktikum Machine Learning yang telah dilakukan menggunakan dataset Heart Disease Prediction, dapat disimpulkan bahwa proses klasifikasi penyakit jantung melibatkan beberapa tahapan penting, mulai dari persiapan dataset, analisis data eksploratif (Exploratory Data Analysis), pemrosesan data (Data Preprocessing), pemilihan model (Model Selection), hingga evaluasi model (Model Evaluation).

Dataset yang digunakan terdiri atas 918 baris data dan 12 kolom yang mencakup berbagai karakteristik serta indikator kesehatan pasien. Melalui analisis data eksploratif, karakteristik dan distribusi setiap variabel dapat dipelajari sebagai dasar untuk memahami struktur data sebelum dilakukan pemodelan.

Pada tahap pemrosesan data, dilakukan pemeriksaan terhadap data yang hilang, data duplikat, dan data pencilan (outliers). Berdasarkan hasil pemeriksaan yang dilaporkan, dataset tidak memiliki data yang hilang maupun duplikat. Penanganan data pencilan dilakukan menggunakan imputasi median, sedangkan fitur kategorik diubah ke dalam representasi numerik menggunakan teknik One-Hot Encoding. Tahapan ini bertujuan mempersiapkan dataset agar dapat digunakan dalam proses klasifikasi.

Selanjutnya, dilakukan pelatihan dan evaluasi terhadap tiga algoritma klasifikasi, yaitu Logistic Regression, Support Vector Machine (SVM), dan Decision Tree. Berdasarkan hasil evaluasi yang dicantumkan dalam laporan, Logistic Regression memperoleh akurasi sebesar 86% pada data pelatihan dan 85% pada data pengujian. Dengan demikian, di antara model yang diuji, Logistic Regression menunjukkan hasil akurasi terbaik berdasarkan hasil yang dilaporkan.

Secara keseluruhan, praktikum ini memberikan pemahaman mengenai penerapan tahapan Machine Learning untuk mengolah data kesehatan dan membangun model klasifikasi. Hasil yang diperoleh menunjukkan bahwa algoritma klasifikasi dapat digunakan untuk mempelajari pola dalam dataset dan

memprediksi kelas berdasarkan variabel yang tersedia. Meskipun demikian, hasil klasifikasi tersebut masih perlu dievaluasi lebih lanjut dan tidak dapat digunakan sebagai pengganti diagnosis medis.

3.2. Saran

Berdasarkan pelaksanaan praktikum dan hasil yang diperoleh, terdapat beberapa saran yang dapat dipertimbangkan untuk pengembangan praktikum selanjutnya.

Peningkatan kualitas pemrosesan data. Proses penanganan data pencilan sebaiknya dilakukan dengan mempertimbangkan karakteristik setiap variabel. Penggantian nilai pencilan menggunakan median perlu dievaluasi agar tidak menghilangkan informasi penting dari data kesehatan.

Penyempurnaan tahapan prapemrosesan. Transformasi data, imputasi, dan penentuan batas pencilan sebaiknya dipelajari dengan memperhatikan pemisahan data pelatihan dan pengujian. Parameter prapemrosesan idealnya ditentukan berdasarkan data pelatihan untuk menghindari kebocoran informasi (data leakage) yang dapat memengaruhi hasil evaluasi.

Penggunaan metode evaluasi yang lebih beragam. Evaluasi model sebaiknya tidak hanya mengandalkan akurasi, tetapi juga mempertimbangkan precision, recall, F1-score, sensitivitas, spesifisitas, dan confusion matrix. Penggunaan metrik tersebut dapat memberikan gambaran yang lebih menyeluruh mengenai kemampuan model dalam mengklasifikasikan kedua kelas.

Pengembangan dan optimasi model. Praktikum selanjutnya dapat menggunakan algoritma klasifikasi tambahan serta melakukan optimasi hiperparameter untuk mengetahui apakah terdapat model yang memberikan kinerja lebih baik. Validasi silang (cross-validation) juga dapat digunakan untuk memperoleh estimasi kinerja model yang lebih andal.

Peningkatan interpretasi hasil. Analisis lebih lanjut terhadap kontribusi variabel dapat dilakukan untuk memahami pola yang dipelajari oleh model. Interpretasi tersebut perlu dilakukan secara hati-hati karena hubungan yang

ditemukan dalam dataset tidak secara otomatis menunjukkan hubungan sebab-akibat.

Penggunaan data yang lebih beragam. Pengujian menggunakan dataset lain yang relevan dapat dipertimbangkan untuk mengetahui kemampuan generalisasi model terhadap data yang berbeda. Hal ini penting sebelum model dipertimbangkan untuk penggunaan di luar lingkungan praktikum.

DAFTAR PUSTAKA

Ahmadi, P., Ahmadi-Renani, S., Pezeshki, P. S., Nayebirad, S., Jalali, A., Shafiee, A., Ayati, A., Afzalian, A., Alaeddini, F., Saadat, S., Masoudkabir, F., Vasheghani-Farahani, A., Sadeghian, S., Boroumand, M., Karimi, A., Pourbashash, B., Hosseini, K., & Rosendaal, F. R. (2025). Association of cardiovascular risk factors with major and minor electrocardiographic abnormalities: A report from the cross-sectional phase of Tehran Cohort Study. Health Science Reports, 8(1), Article e70350. https://doi.org/10.1002/hsr2.70350

Al-Alshaikh, H. A., P, P., Poonia, R. C., Saudagar, A. K. J., Yadav, M., AlSagri, H. S., & AlSanad, A. A. (2024). Comprehensive evaluation and performance analysis of machine learning in heart disease prediction. Scientific Reports, 14(1), Article 7819. https://doi.org/10.1038/s41598-024-58489-7

Ali, M. M., Paul, B. K., Ahmed, K., Bui, F. M., Quinn, J. M. W., & Moni, M. A. (2021). Heart disease prediction using supervised machine learning algorithms: Performance analysis and comparison. Computers in Biology and Medicine, 136, Article 104672. https://doi.org/10.1016/j.compbiomed.2021.104672

Bhatt, C. M., Patel, P., Ghetia, T., & Mazzeo, P. L. (2023). Effective heart disease prediction using machine learning techniques. Algorithms, 16(2), Article 88. https://doi.org/10.3390/a16020088

El-Sofany, H. F. (2024). Predicting heart diseases using machine learning and different data classification techniques. IEEE Access, 12, 106146–106160. https://doi.org/10.1109/ACCESS.2024.3437181

Harish Kumar, M., & Lakshmanan, S. (2025). Comparative analysis of classification models for heart disease prediction using machine learning. 2025 International Conference on Inventive Computation Technologies (ICICT), 1–6. https://doi.org/10.1109/ICICT63935.2025.11005114

Iakunchykova, O., Lange, T., & Leon, D. A. (2024). Multiplicative and additive interactions between risk factors for coronary heart disease. Annals of Epidemiology, 91, 82–84. https://doi.org/10.1016/j.annepidem.2023.11.012

Jousilahti, P., Vartiainen, E., Tuomilehto, J., & Puska, P. (1999). Sex, age, cardiovascular risk factors, and coronary heart disease: A prospective follow-up study of 14 786 middle-aged men and women in Finland. Circulation, 99(9), 1165–1172. https://doi.org/10.1161/01.cir.99.9.1165

Jrab, D., Eleyan, D., Eleyan, A., & Bejaoui, T. (2024). Heart disease prediction using machine learning algorithms. 2024 International Conference on Smart Applications, Communications and Networking (SmartNets), 1–8. https://doi.org/10.1109/SmartNets61466.2024.10577725

Mohan, S., Thirumalai, C., & Srivastava, G. (2019). Effective heart disease prediction using hybrid machine learning techniques. IEEE Access, 7, 81542–81554. https://doi.org/10.1109/access.2019.2923707

Ozcan, M., & Peker, S. (2023). A classification and regression tree algorithm for heart disease modeling and prediction. Healthcare Analytics, 3, Article 100130. https://doi.org/10.1016/j.health.2022.100130

Pencina, M., Navar, A., Wojdyla, D., Sanchez, R., Khan, I., Elassal, J., D'Agostino, R., Peterson, E., & Sniderman, A. (2018). Quantifying importance of major risk factors for coronary heart disease. Circulation, 139(13), 1603–1611. https://doi.org/10.1109/circulationaha.117.031855

Rehman, M. U., Naseem, S., & Butt, A. (2025). Predicting coronary heart disease with advanced machine learning classifiers for improved cardiovascular risk assessment. Scientific Reports, 15(1), Article 13361. https://doi.org/10.1038/s41598-025-96437-1

Sahranavard, T., Alimi, R., Arabkhazaei, J., Nasrabadi, M., Alavi Dana, S. M. M., Gholami, Y., Izadi-Moud, A., Esmaily, H., Ebrahimi, M., Ferns, G. A., & Mobarhan, M. G. (2024). Association of major and minor ECG abnormalities with traditional cardiovascular risk factors in the general population: A large scale study. Scientific Reports, 14(1), Article 11289. https://doi.org/10.1038/s41598-024-62142-8

Sinha, A. K., Singh, A., & Singh, S. (2024). Coronary heart disease at the tertiary care hospital. 8th IET Smart Cities Symposium (SCS 2024), 442–446. https://doi.org/10.1049/icp.2025.0953

van Bussel, E. F., Hoevenaar-Blom, M. P., Poortvliet, R. K. E., Gussekloo, J., van Dalen, J. W., van Gool, W. A., Richard, E., & Moll van Charante, E. P. (2020). Predictive value of traditional risk factors for cardiovascular disease in older people: A systematic review. Preventive Medicine, 132, Article 105986. https://doi.org/10.1016/j.ypmed.2020.105986

Wilson, P., D'Agostino, R., Levy, D., Belanger, A. M., Silbershatz, H., & Kannel, W. (1998). Prediction of coronary heart disease using risk factor categories. Circulation, 97(18), 1837–1847. https://doi.org/10.1161/01.cir.97.18.1837

Yu, L., Ye, X., Yang, Z., Yang, W., Zhang, B., & China National Diabetes and Metabolic Disorders Study Group. (2020). Prevalences and associated factors of electrocardiographic abnormalities in Chinese adults: A cross-sectional study. BMC Cardiovascular Disorders, 20(1), Article 414. https://doi.org/10.1186/s12872-020-01698-5